UNIVERSIDAD NACIONAL DE INGENIERÍA • FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

TUTOR VIRTUAL 24/7

Centro de Especialización Ejecutiva FIIS - UNI

Avance de Investigación Tecnológica — Grupo 5

Propuesta tecnológica preliminar, sujeta a validación de infraestructura y requerimientos con el Área de TI del CEE.

Curso	Sistemas Integrados Empresariales
Universidad	Universidad Nacional de Ingeniería — UNI
Grupo	Grupo 5
Proyecto	Tutor Virtual 24/7
Fecha	19 de septiembre de 2026
Dirigido a	Sr. César Dionicio, Coordinador del Área de TI del Centro de Especialización Ejecutiva FIIS - UNI (CEE FIIS-UNI)

Estado del documento

Este documento es una **propuesta tecnológica preliminar** resultado de una investigación inicial. **No describe un sistema implementado.** Las decisiones de infraestructura, modelo de IA y despliegue quedan sujetas a la validación con el Área de TI del CEE.

Índice

Resumen ejecutivo . . . 3
1. Contexto y objetivo . . . 4
2. Definición del Tutor Virtual . . . 4
3. Funcionalidades . . . 5
4. Restricción de costo S/ 0 . . . 6
5. Supuesto de infraestructura . . . 7
6. Arquitectura propuesta . . . 7
7. Tecnologías propuestas . . . 9
8. Cumplimiento del costo S/ 0 por tecnología . . . 14
9. Alternativas tecnológicas . . . 15
10. Disponibilidad 24/7 . . . 17
11. Escalabilidad . . . 17
12. Seguridad . . . 18
13. Privacidad y datos . . . 18
14. Control de alucinaciones . . . 19
15. Actualización de la base de conocimiento . . . 19
16. MVP propuesto . . . 20
17. Roadmap propuesto . . . 20
18. Preguntas pendientes para el Área de TI del CEE . . . 21
19. Riesgos . . . 21
20. Decisiones para la reunión con TI . . . 22
21. Conclusión . . . 23
Referencias . . . 23

Resumen ejecutivo

El Grupo 5 propone un **Tutor Virtual 24/7**: un asistente académico conversacional que responde consultas de los alumnos del CEE FIIS-UNI usando únicamente la información y los materiales que el propio CEE proporcione y valide. No pretende ser un asistente genérico, sino un tutor especializado en el conocimiento del CEE.

La arquitectura preliminar combina un **modelo de lenguaje local** (ejecutado con Ollama), una **base de conocimiento del CEE** y la técnica **RAG** (generación aumentada por recuperación), con backend en Python/FastAPI, interfaz web en React/Vite, SQLite como base de datos inicial, Nginx como punto de entrada y Docker para el despliegue. **Ningún componente principal depende de APIs comerciales de IA ni de pago por tokens.**

Lo que este documento afirma y lo que no

- **Costo de software S/ 0:** las licencias del stack propuesto fueron verificadas y no exigen pago para este uso (con las salvedades de la sección 4).
- **El costo total no es S/ 0 por sí solo:** hardware, electricidad, Internet y un dominio propio pueden generar gastos. Software gratuito no equivale a infraestructura gratuita.
- **El modelo LLM no está elegido.** Depende del hardware disponible, que aún se desconoce.
- **24/7 es un objetivo de diseño, no una garantía.** Requiere que el equipo que aloja el sistema permanezca encendido y conectado.

Cuatro alertas encontradas durante la investigación

1. Ollama tiene planes de nube de pago (Pro, Max); solo se usarán modelos locales [3].

2. Docker Desktop exige suscripción de pago para entidades gubernamentales; se propone Docker Engine sobre Ubuntu [20].

3. Cloudflare Tunnel no reemplaza al servidor, sus túneles rápidos no tienen garantía de disponibilidad y un túnel estable requiere un dominio propio [29].

4. Chroma Cloud, Ollama Cloud y otros servicios en la nube no forman parte de la propuesta.

Cómo leer este documento

Etiqueta	Significado
HECHO	Dato verificado en la fuente indicada entre corchetes, por ejemplo [1]. Las fuentes secundarias se señalan como tales en las referencias.
PROPUESTA	Decisión de diseño que el Grupo 5 plantea como preliminar. Puede cambiar.
SUPUESTO	Supuesto de trabajo que todavía no fue confirmado con el CEE.

1. Contexto y objetivo

1.1 Contexto del proyecto

El proyecto forma parte del curso **Sistemas Integrados Empresariales** de la Universidad Nacional de Ingeniería (UNI). Los estudiantes colaboran con el Centro de Especialización Ejecutiva FIIS - UNI (CEE) para investigar y proponer soluciones tecnológicas a distintas necesidades. Los proyectos asignados son:

Grupo	Proyecto
Grupo 1	Dashboard de análisis de redes del CEE
Grupo 2	CRM
Grupo 3	Campus virtual del CEE
Grupo 4	Aplicativo de análisis de cursos, precios y temarios más demandados por semanas o meses
Grupo 5	**Tutor Virtual 24/7 que resuelva consultas de los alumnos (este documento)**

El coordinador del Área de TI del CEE solicitó que cada grupo presente su avance de investigación de tecnologías y luego se realice una reunión de coordinación con los representantes de cada grupo para debatir las tecnologías propuestas.

1.2 Objetivo de este documento

- Explicar qué problema pretende resolver el Grupo 5 y en qué consistirá el Tutor Virtual.
- Presentar las funcionalidades previstas y las que quedan fuera del MVP.
- Proponer una arquitectura tecnológica preliminar y justificar cada tecnología.
- Mostrar cómo se plantea cumplir el requisito de **costo S/ 0** sin depender de APIs comerciales ni de pago por tokens.
- Identificar la infraestructura necesaria y lo que todavía debe validarse con el Área de TI.

> **Alcance**
> Este documento **no** presenta el proyecto como implementado. Es una propuesta preliminar que será ajustada según las respuestas del Área de TI y los acuerdos de la reunión de coordinación (domingo 20 de septiembre de 2026, 3:00 p. m.).

2. Definición del Tutor Virtual

> **Definición**
> Un **asistente académico conversacional** especializado en la información y los contenidos del Centro de Especialización Ejecutiva FIIS-UNI, capaz de responder consultas de los alumnos sobre cursos, programas, temarios y materiales académicos, utilizando una base de conocimiento proporcionada y validada por el CEE.

Lo que NO es. No se busca crear un “ChatGPT genérico”. El objetivo es crear un tutor especializado en el conocimiento académico e institucional que el CEE proporcione.

Problema que resuelve. Los alumnos pueden tener dudas fuera del horario de atención sobre cursos, temarios o conceptos del material, y hoy dependen de que una persona del CEE o un docente esté disponible para responderlas. El tutor ofrece una primera respuesta inmediata, basada en material validado, y orienta hacia un canal humano cuando no dispone de información suficiente.

Principios de diseño

- **Especializado:** responde con base en los documentos del CEE, no en conocimiento general.
- **Honesto:** si no encuentra información suficiente, lo dice; no inventa respuestas.
- **Trazable:** cuando sea posible, indica de qué documentos tomó la información.
- **Autónomo:** funciona con software local, sin depender de proveedores que cobren por consulta.
- **Modular:** se puede integrar después con otros sistemas del CEE (Campus Virtual, CRM).

3. Funcionalidades

3.1 Funcionalidades del MVP

Funcionalidad	Descripción	Ejemplo de uso
Consultas académicas en lenguaje natural	El alumno pregunta con sus propias palabras.	"¿Qué temas se desarrollan en este curso?", "¿Cuál es la diferencia entre logística y Supply Chain?"
Consulta de información de cursos	Responde con nombre, descripción, objetivos, temario, módulos, duración, modalidad y materiales disponibles.	"¿Cuánto dura el programa y qué módulos incluye?"
Consulta de documentos académicos	Consulta PDFs, presentaciones, manuales, separatas y material que proporcione el CEE, indicando la fuente.	"Resume la separata del módulo 2."
Explicación personalizada	Explicaciones sencillas o detalladas, ejemplos, resúmenes, analogías y reexplicaciones.	"Explícame el concepto de inventario de seguridad de manera sencilla."
Generación de ejercicios	Preguntas de práctica, alternativa múltiple y mini cuestionarios; evalúa respuestas y explica por qué son correctas o incorrectas.	"Hazme 5 preguntas de práctica sobre este tema."
Preguntas frecuentes	Responde información previamente validada por el CEE.	"¿Cómo solicito información de un programa?"
Memoria de la conversación	Mantiene el contexto de la conversación actual.	Tras "Explícame el método ABC", entiende que "Dame un ejemplo" se refiere al método ABC.
Manejo de preguntas desconocidas	No inventa; indica que no dispone de información suficiente y orienta hacia un canal humano del CEE.	Pregunta sobre un tema que no está en la base de conocimiento.

3.2 Funcionalidades fuera del MVP

Inicialmente **no** se contemplan las siguientes funciones. Podrían corresponder a otros sistemas del ecosistema del CEE, como el Campus Virtual (Grupo 3) o el CRM (Grupo 2):

No incluido en el MVP	Sistema del ecosistema al que podría corresponder
Matrícula	Campus Virtual / CRM
Pagos y gestión financiera	Sistemas administrativos del CEE
Emisión de certificados	Campus Virtual / sistemas administrativos
Modificación de notas y gestión oficial de asistencia	Campus Virtual
Gestión administrativa completa y administración de docentes	Campus Virtual / sistemas administrativos

La asignación a cada sistema es una sugerencia del Grupo 5 y debe confirmarse con el CEE.

4. Restricción de costo S/ 0

4.1 Qué significa

La solución debe evitar: APIs de IA de pago; pago por tokens; suscripciones mensuales; servicios cloud que requieran pago; créditos gratuitos que luego obliguen a pagar; servicios cuya continuidad dependa de una tarjeta bancaria; proveedores que cobren según el número de consultas; y licencias comerciales necesarias para que el sistema funcione.

Por eso **no** se propone como arquitectura principal ninguna de estas opciones: OpenAI API de pago, Google Gemini API de pago, Anthropic API, Azure OpenAI, Amazon Bedrock ni cualquier API comercial con cobro por tokens. La propuesta prioriza software open source, gratuito, autoalojado, ejecutable localmente y sin costos variables por cantidad de consultas.

4.2 Cuatro categorías que no deben confundirse

Categoría	Definición	Ejemplos en este proyecto	Uso en la propuesta
1. Software open source o gratuito	Se instala y ejecuta en infraestructura propia; la licencia permite el uso sin pago.	Ollama (local), ChromaDB, FastAPI, SQLite, Nginx, Docker Engine, Ubuntu Server.	**Base de la arquitectura.**
2. Servicios cloud con free tier	Servicio alojado por un tercero con un nivel gratuito acotado.	Ollama Cloud (plan Free), Chroma Cloud (crédito inicial de US$ 5) [3,7].	**No se usan.** Son un punto de entrada a un servicio de pago.
3. Servicios gratuitos con límites	Gratuitos, pero con topes de uso o funciones.	GitHub Free (funciones limitadas en repositorios privados); Cloudflare Zero Trust Free (hasta 50 usuarios) [27,30].	Uso acotado y solo para tareas no críticas. Límites declarados.
4. Servicios que eventualmente requieren pago	Pueden exigir pago según el caso de uso, la organización o el volumen.	Planes Pro/Max de Ollama Cloud; Docker Desktop en entidades gubernamentales; dominio propio; Ubuntu Pro (soporte extendido) [3,20,24].	Evitados o declarados explícitamente.

4.3 Software gratuito no es infraestructura gratuita

El software puede costar S/ 0 mientras que el **hardware, la electricidad, el acceso a Internet, un dominio propio, el almacenamiento de respaldos y las horas de mantenimiento** sí pueden generar costos. Este documento declara esa diferencia y no la oculta: la viabilidad económica final depende de qué infraestructura ya exista en el CEE o la UNI.

> **Prueba de diseño "S/ 0"**
> Si se cancelaran todas las cuentas externas (Ollama Cloud, Chroma Cloud, Docker Desktop, etc.), **el Tutor Virtual debe seguir funcionando** dentro de la red del CEE. Solo el acceso desde Internet depende de un servicio de terceros, y es opcional.

5. Supuesto de infraestructura

> **Supuesto de trabajo (por validar con TI)**
> El CEE **no dispone actualmente de un servidor dedicado conocido** para este proyecto. Actualmente no se sabe si cuenta con servidor físico, máquina virtual, PC utilizable como servidor, servidor institucional de la UNI, servicio cloud institucional, GPU, recursos de CPU y RAM suficientes, conexión a Internet adecuada o dominio institucional.

Escenario base PROPUESTA: el sistema se ejecutaría en una computadora o servidor disponible del CEE, o en infraestructura institucional que el Área de TI determine posteriormente. **Esta decisión debe ser validada con el coordinador de TI.**

Escenario posible	Descripción	Implicancia para el proyecto
A. PC o servidor del CEE sin GPU	Equipo disponible que permanecería encendido.	El LLM correría en CPU y memoria RAM. Habría que medir si el tiempo de respuesta es aceptable con modelos pequeños.
B. Equipo del CEE con GPU	Equipo con tarjeta gráfica compatible.	Permite modelos más grandes o más usuarios; el límite lo fija la VRAM disponible [4].
C. Infraestructura institucional de la UNI	Máquina virtual o servidor provisto por la UNI.	Requiere coordinar accesos, políticas de seguridad y recursos asignados.
D. Sin infraestructura disponible	Ninguna de las anteriores.	Se requeriría una decisión de la institución (fuera del alcance de S/ 0 de software); el alcance del MVP podría reducirse.

Los escenarios son hipótesis para ordenar la conversación con TI; no se asignan cifras de capacidad porque dependen del hardware real y del modelo elegido.

6. Arquitectura propuesta

La arquitectura es modular: cada pieza puede cambiarse sin rehacer las demás. Todo se ejecutaría inicialmente en un mismo servidor, empaquetado en contenedores. La Figura 1 muestra el diagrama completo y la tabla resume cada componente. **PROPUESTA**

6.1 Componentes y responsabilidades

Componente	Rol	Se comunica con
Interfaz web (React + Vite)	Chat del alumno en el navegador.	Nginx (HTTP/HTTPS)
Nginx	Reverse proxy y punto de entrada; único servicio expuesto.	Frontend y FastAPI
FastAPI	Recibe consultas, ejecuta el flujo RAG, gestiona conversaciones y registra logs.	ChromaDB, Ollama, SQLite
ChromaDB	Almacena embeddings de los fragmentos de documentos y responde búsquedas semánticas.	FastAPI
Ollama + LLM local	Ejecuta el modelo de lenguaje y genera la respuesta.	FastAPI
SQLite	Usuarios, conversaciones, mensajes, configuraciones y logs.	FastAPI
Base de conocimiento del CEE	Documentos validados: temarios, separatas, manuales, FAQs.	Proceso de ingesta

6.2 Diagrama de arquitectura

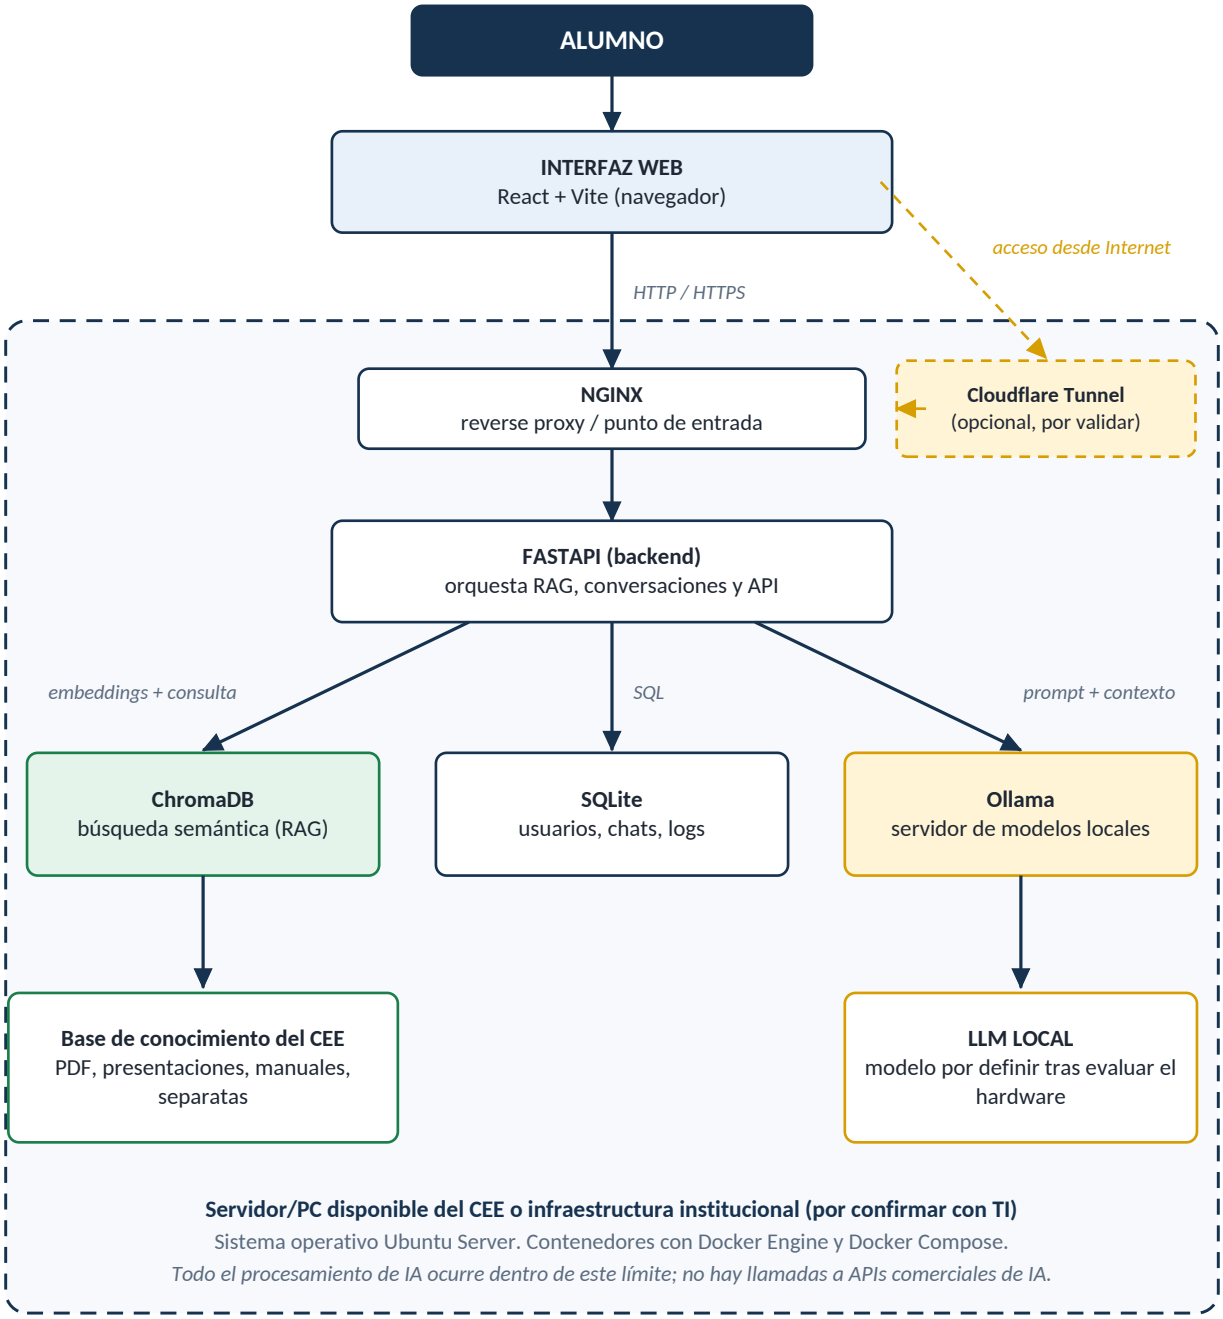


Figura 1. Arquitectura preliminar del Tutor Virtual 24/7 (diagrama del Grupo 5).

6.3 Flujo completo de una consulta

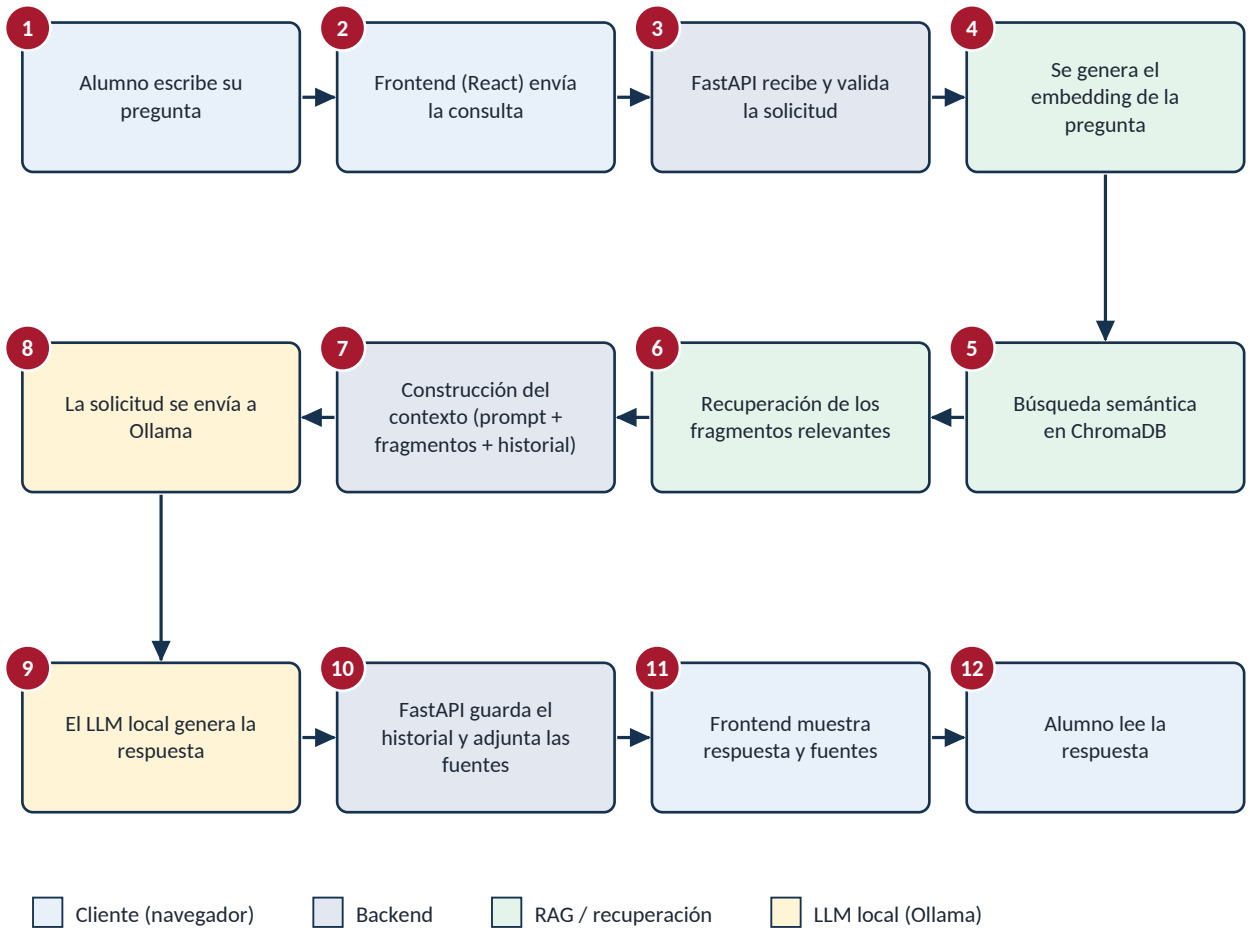


Figura 2. Recorrido de una consulta, desde la pregunta del alumno hasta la respuesta.

Los pasos 4 a 7 corresponden a la recuperación (RAG) y los pasos 8 y 9 a la generación con el LLM local en Ollama. Los pasos 1, 2, 11 y 12 ocurren en el navegador del alumno.

7. Tecnologías propuestas

Cada subsección responde tres preguntas: qué es, para qué se usaría y por qué se propone. La licencia y el costo se resumen en la sección 8.

7.1 Ollama y modelos de lenguaje locales

Qué es. Ollama es una plataforma de código abierto para descargar, ejecutar y gestionar modelos de lenguaje en equipos propios. Está publicada bajo licencia MIT, expone una API REST local (por defecto en el puerto 11434) y ofrece una imagen Docker oficial [1,2]. Su motor de inferencia es llama.cpp [1].

Para qué se usaría. Para ejecutar el LLM dentro de la infraestructura del CEE. El backend FastAPI le envía el prompt (pregunta + contexto recuperado) mediante peticiones HTTP a la API local y recibe la respuesta. Como el modelo corre localmente, **no hay pago por tokens ni envío de consultas a proveedores externos**.

Ventajas	Limitaciones
Uso local gratuito e ilimitado en hardware propio [3]. Instalación sencilla y API estándar. Biblioteca amplia de modelos abiertos. Control sobre los datos.	El rendimiento depende del hardware (CPU, RAM, GPU/VRAM). Sin GPU, las respuestas pueden ser lentas. Las solicitudes en paralelo multiplican la memoria necesaria para el contexto [4]. Además, Ollama ofrece modelos en su nube, que son de pago: no se usarán.

Requisitos de hardware: no existe un mínimo único

Ollama no publica un mínimo universal de RAM o VRAM: depende del modelo, del tamaño de contexto y de la concurrencia [4]. Como referencia orientativa de una fuente secundaria, un modelo de 7B a 8B parámetros con cuantización Q4 y contexto de 8K puede requerir del orden de 6 a 7 GB de VRAM con una sola solicitud activa [4]. **No es una especificación oficial** y no reemplaza las pruebas en el equipo real.

7.2 Selección del modelo LLM (no definitiva)

Decisión pendiente SUPUESTO

El modelo concreto **no se selecciona todavía**. Se elegirá después de conocer CPU, RAM, GPU, VRAM, sistema operativo, número esperado de usuarios y de consultas simultáneas, y de evaluar rendimiento y calidad con preguntas reales del CEE.

A modo de ejemplo, estos son candidatos que se podrían evaluar. Su inclusión no implica que sean la decisión final:

Familia de modelos	Licencia (según fuentes)	Observaciones para el proyecto
Gemma 4 (Google)	Apache 2.0 [5]	Cambió de una licencia propia a Apache 2.0 en abril de 2026 [5]. Verificar tamaño y variante en la ficha del modelo.
Qwen (Alibaba)	Apache 2.0 (Qwen 3 y 3.5) [6]	Verificar la versión concreta y su ficha oficial.
Llama (Meta)	Licencia comunitaria propia [6]	Con condiciones (por ejemplo, atribución y umbrales de uso). No es equivalente a Apache 2.0; requiere lectura cuidadosa.

Criterios de evaluación propuestos: calidad de respuesta en español sobre material del CEE; fidelidad al contexto recuperado (que no invente); tiempo de respuesta; consumo de memoria; estabilidad con varios usuarios; y licencia. La evaluación se hará en la Fase 3 del roadmap.

7.3 RAG: generación aumentada por recuperación

Por qué RAG. No se pretende entrenar un modelo de IA desde cero ni reentrenarlo con cada documento. En su lugar, se combina un LLM local con la base de conocimiento del CEE: el sistema busca los fragmentos relevantes y se los entrega al modelo como contexto para que redacte la respuesta.

LLM local + **Base de conocimiento del CEE** + **RAG** = **Tutor especializado**

Ventajas frente a reentrenar: el conocimiento se actualiza agregando documentos, sin reentrenar el modelo; las respuestas pueden apoyarse en documentos concretos y mostrar sus fuentes; y se reduce (no se elimina) el riesgo de respuestas inventadas.

Paso	Qué ocurre	Etapa
1	El CEE proporciona los documentos.	Ingesta
2	Se extrae el texto de cada documento.	Ingesta
3	Los documentos se dividen en fragmentos.	Ingesta
4	Se generan embeddings de cada fragmento.	Ingesta

Paso	Qué ocurre	Etapa
5	Los embeddings se almacenan en una base vectorial.	Ingesta
6	El alumno realiza una pregunta.	Consulta
7	La pregunta se convierte en embedding.	Consulta
8	Se buscan los fragmentos más relevantes.	Consulta
9	Los fragmentos recuperados se entregan al LLM.	Consulta
10	El LLM genera la respuesta usando ese contexto.	Consulta

7.4 Base vectorial: ChromaDB

Qué es. ChromaDB es una base de datos vectorial de código abierto (licencia Apache 2.0) que almacena embeddings junto con metadatos y permite búsquedas por similitud, con filtros por metadatos [7]. Se instala como paquete de Python y puede funcionar en memoria, con persistencia o en modo cliente-servidor [7].

Para qué se usaría. Guardar los fragmentos de los documentos del CEE (con metadatos como nombre del documento, curso y página) y recuperar los más parecidos a la pregunta del alumno.

Por qué encaja en un proyecto autoalojado. Es sencilla de operar, tiene una API pequeña y no exige un servicio externo. Costo de software: S/ 0 en modo local. **Limitaciones a considerar:** Chroma también ofrece un servicio en la nube (Chroma Cloud) con crédito inicial limitado, que **no** se usará [7]; el proyecto evoluciona con rapidez y publica versiones con frecuencia semanal [7], por lo que conviene fijar versiones; y su comportamiento con volúmenes grandes debe validarse con los datos reales del CEE.

7.5 Embeddings: Sentence Transformers

Qué son los embeddings. Son vectores numéricos que representan el significado de un texto. Textos con significado parecido quedan cerca entre sí, lo que permite buscar por sentido y no solo por palabras exactas.

Cómo se generarían localmente. Sentence Transformers es un módulo de Python de código abierto (Apache 2.0), creado por UKPLab y mantenido por Hugging Face, para calcular embeddings y entrenar o usar modelos de texto [8]. Su documentación indica que existen más de 5 000 modelos preentrenados disponibles en Hugging Face [8]. Al calcularse en el propio servidor, **no se necesita una API comercial de embeddings**.

Impacto en CPU y RAM. Los embeddings se calculan en la ingesta (por cada fragmento) y en cada consulta (una vez por pregunta). El costo depende del tamaño del modelo de embeddings; no se asignan cifras hasta medirlas en el equipo real.

Factores para elegir el modelo de embeddings: calidad en español; tamaño del modelo y consumo de memoria; dimensión del vector; longitud máxima de texto admitida; velocidad en CPU; **licencia propia de ese modelo** (distinta de la de la biblioteca); y consistencia (el mismo modelo debe usarse para indexar y para consultar).

7.6 Backend: Python + FastAPI

Qué es. Python es el lenguaje del backend (licencia de la Python Software Foundation, que permite su uso sin regalías [25]). FastAPI es un framework web para construir APIs en Python, de licencia MIT [12] y con soporte de programación asíncrona (asyncio) [12].

Por qué sería apropiado. Python concentra el ecosistema de IA (Sentence Transformers, clientes de Ollama y de ChromaDB); usar un solo lenguaje para RAG y para la API simplifica el proyecto.

Responsabilidad	Cómo la cumpliría el backend
Comunicación con Ollama	Llamadas HTTP a la API REST local de Ollama (o su cliente de Python) [2].
Comunicación con ChromaDB	Cliente de Python de Chroma, en modo embebido o cliente-servidor [7].
Manejo de consultas	Endpoint de chat que valida la solicitud, ejecuta el flujo RAG y devuelve la respuesta y las fuentes.

Responsabilidad	Cómo la cumpliría el backend
Gestión de conversaciones	Guarda mensajes en SQLite y reconstruye el contexto reciente para cada nueva pregunta.
Integración futura	API REST documentable que otros sistemas del CEE (Campus Virtual, CRM) podrían consumir. **PROPUESTA**

7.7 Frontend: React + Vite

Qué son. React es una biblioteca de JavaScript para construir interfaces de usuario, de licencia MIT [14]. Vite es una herramienta de desarrollo y compilación para proyectos web; según los metadatos de su paquete es de licencia MIT y requiere Node.js 20.19 o superior (o 22.12 o superior) [15].

Cómo se utilizarían. React construiría el chat web (mensajes, historial, entrada de texto) y Vite generaría los archivos estáticos que Nginx serviría. Ambos tienen costo de licencia S/ 0.

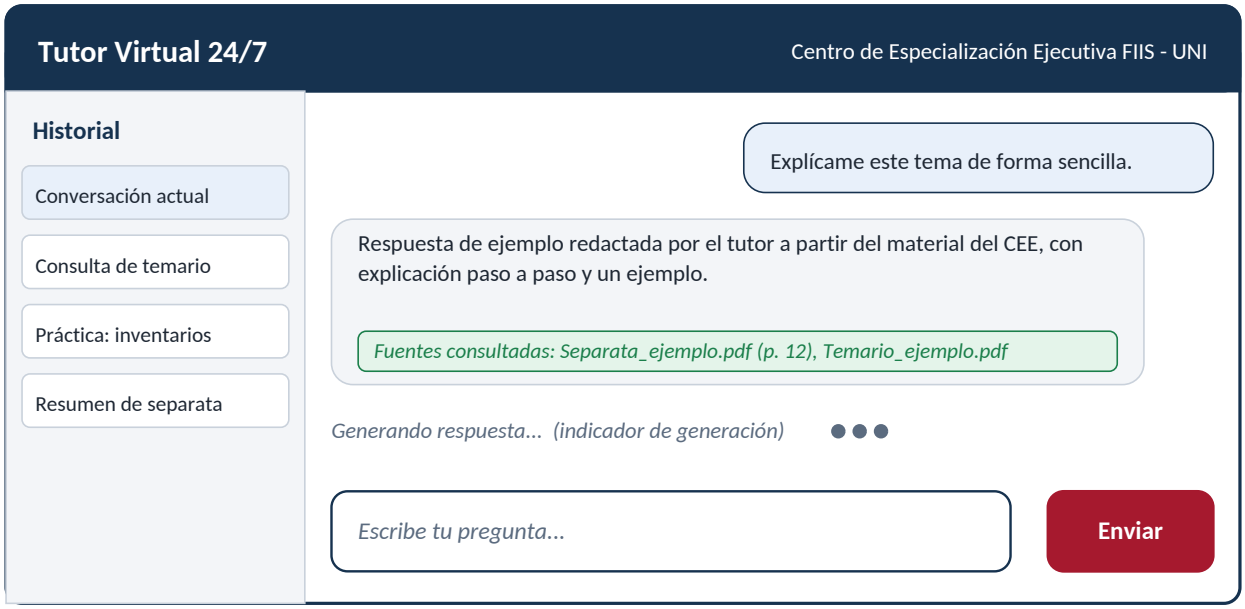


Figura 3. Boceto conceptual de la interfaz del alumno (ilustrativo; no representa el diseño final ni contenido real).

Elementos previstos: encabezado del Tutor Virtual; área de conversación; campo de pregunta y botón enviar; historial de conversaciones; indicador de generación; y la posibilidad de mostrar las fuentes o documentos consultados.

7.8 Base de datos: SQLite

Por qué puede ser suficiente para el MVP. SQLite es de dominio público, por lo que puede usarse con cualquier fin, comercial o no, sin pagar licencia [17]. Es una base de datos embebida en un archivo, sin servidor aparte, lo que simplifica la instalación y las copias de seguridad.

Qué almacenaría: usuarios, conversaciones, mensajes, configuraciones y registros (logs) de uso.

Cuándo migrar a PostgreSQL (licencia PostgreSQL License, permisiva [18]): cuando haya muchos usuarios escribiendo a la vez, se necesiten varios procesos o servidores accediendo a la misma base, políticas de respaldo y replicación más exigentes, o integración con otros sistemas del CEE que ya usen PostgreSQL. **PROPUESTA**

7.9 Servidor web: Nginx

Nginx se distribuye bajo una licencia BSD de 2 cláusulas [19]. Su función sería: **reverse proxy** (recibe las solicitudes y las reenvía al backend), **servidor web** de los archivos del frontend, **punto de entrada único** al sistema y manejo de solicitudes HTTP/HTTPS. Ollama y ChromaDB no se expondrían directamente: solo Nginx sería accesible desde la red.

7.10 Contenedores: Docker Engine y Docker Compose

Docker permitiría empaquetar frontend, backend, Ollama, ChromaDB y Nginx en contenedores, y Docker Compose los describiría y levantaría con un solo archivo. Docker Engine se distribuye bajo licencia Apache 2.0 para Linux [21] y Docker Compose también es Apache 2.0 [23].

Aspecto	Ventaja
Instalación	Un archivo de definición levanta todo el conjunto de servicios.
Portabilidad	El mismo entorno puede moverse a otro servidor del CEE o de la UNI.
Mantenimiento	Actualizar o revertir una pieza sin afectar a las demás.
Reproducción del entorno	Cualquier integrante del equipo puede replicar el mismo entorno.
Despliegue	Los contenedores pueden configurarse para iniciarse automáticamente tras un reinicio [22].

> **Advertencia de licencia: Docker Desktop**
> La documentación oficial indica que Docker Desktop es gratuito para pequeñas empresas, uso personal, educación y proyectos de código abierto no comerciales, pero requiere suscripción de pago para **entidades gubernamentales** y organizaciones grandes; los términos de Docker Engine no cambian [20]. La UNI es una universidad pública y **no se sabe si Docker la consideraría entidad gubernamental**. Por eso se propone Docker Engine sobre Ubuntu Server y no Docker Desktop. Este punto debe consultarse con TI.

7.11 Sistema operativo: Ubuntu Server

Ubuntu Server es de descarga y uso gratuitos. Sus versiones LTS ofrecen cinco años de actualizaciones de seguridad y mantenimiento sin costo, ampliables con Ubuntu Pro (opcional y de pago según el caso) [24]. La versión LTS más reciente indicada por el sitio oficial es la 26.04.1 [24]. Los requisitos mínimos solo para instalar el sistema son 1,5 GB de RAM y 5 GB de disco [24]; los requisitos reales del proyecto son mucho mayores porque dependen del modelo de IA.

Compatibilidad: Docker Engine dispone de instrucciones oficiales de instalación para Ubuntu [20]; Ollama publica un instalador para Linux [1]; Python, ChromaDB y Sentence Transformers se instalan como paquetes de Python en Linux [7,8]. Se propone comprobar la compatibilidad exacta de versiones en la Fase 2.

7.12 Control de versiones: Git y GitHub

Git es software libre y de código abierto bajo la licencia GPLv2 [26]. Permite historial de cambios, ramas (branches) y trabajo colaborativo. GitHub sería el servicio donde se aloja el repositorio, con gestión de issues y revisión de cambios.

Qué es gratuito y qué tiene límites. GitHub Free permite colaboradores y repositorios públicos ilimitados con todas las funciones, y repositorios privados ilimitados con un conjunto de funciones limitado; incluye una cuota mensual de minutos de GitHub Actions (2 000 minutos según la documentación consultada), mientras que funciones como ramas protegidas en repositorios privados están en planes de pago [27]. Las condiciones cambian: deben confirmarse en la página de precios vigente [27]. **GitHub es un servicio gratuito con límites (categoría 3), no software libre.**

7.13 Acceso desde Internet: Cloudflare Tunnel

Cómo funcionaría. Un programa ligero (cloudflared) instalado en el servidor crea conexiones **solo salientes** hacia la red de Cloudflare, sin necesidad de una IP pública enrutable ni de abrir puertos entrantes en el firewall [28]. Los alumnos accederían a través de Cloudflare y esta reenviaría el tráfico al servidor del CEE.

> **Advertencias importantes**
>
> **1. No reemplaza al servidor.** El equipo que ejecuta el Tutor Virtual debe permanecer encendido y conectado; el túnel solo es la vía de acceso.
>
> **2. Los túneles rápidos (trycloudflare.com) no sirven para producción.** No requieren cuenta, pero no tienen garantía de disponibilidad, la URL cambia al reiniciar y Cloudflare los presenta como herramienta de depuración [29].
>
> **3. Un túnel estable requiere una cuenta y una zona (dominio) que se controle** [29]. Un dominio propio puede tener costo; se consultará a TI si puede proveer un subdominio institucional.
>
> **4. El plan gratuito de Zero Trust cubre hasta 50 usuarios** según una fuente secundaria [30], por lo que no debe usarse para autenticar a todos los alumnos. La autenticación se resolverá en la propia aplicación.
>
> **5. Privacidad:** el tráfico pasaría por la red de un tercero (Cloudflare). Esto debe evaluarse frente a la política de datos del CEE. **PROPUESTA**

Su condición de servicio gratuito o de pago debe confirmarse en las páginas oficiales de Cloudflare [30]; la propuesta funciona sin él si el acceso se limita a la red interna del CEE o de la UNI.

8. Cumplimiento del costo S/ 0 por tecnología

La tabla resume la licencia y el costo del **software** de cada tecnología, según las fuentes citadas. No incluye hardware, electricidad, Internet ni dominio.

Tecnología	Función	Tipo de licencia	Costo	¿API de pago?	Observaciones
Python	Lenguaje del backend	PSF License [25]	S/ 0	No	Licencia permisiva y sin regalías.
FastAPI	Framework de API	MIT [12]	S/ 0	No	Verificado en fuente oficial.
Ollama	Ejecutar LLM local	MIT [1]	S/ 0 (local)	No	Tiene una nube de pago (Pro/Max) [3]: **no usar modelos cloud**.
Modelo LLM	Generar respuestas	Según el modelo [5,6]	S/ 0	No	**Por definir.** Verificar la licencia de la ficha oficial del modelo elegido.
ChromaDB	Base vectorial	Apache 2.0 [7]	S/ 0 (local)	No	Chroma Cloud es un servicio aparte: no se usa.
Sentence Transformers	Embeddings locales	Apache 2.0 [8]	S/ 0	No	Cada modelo de embeddings tiene su propia licencia.
React	Interfaz web	MIT [14]	S/ 0	No	—
Vite	Compilación del frontend	MIT [15]	S/ 0	No	Requiere Node.js 20.19+ o 22.12+ [15].
SQLite	Base de datos del MVP	Dominio público [17]	S/ 0	No	No requiere licencia.
Nginx	Reverse proxy	BSD 2 cláusulas [19]	S/ 0	No	—
Docker Engine	Contenedores	Apache 2.0 [21]	S/ 0	No	**Usar Engine, no Desktop** [20].

Tecnología	Función	Tipo de licencia	Costo	¿API de pago?	Observaciones
Docker Compose	Orquestación de contenedores	Apache 2.0 [23]	S/ 0	No	—
Ubuntu Server	Sistema operativo	Libre [24]	S/ 0	No	5 años de seguridad gratis en LTS; Ubuntu Pro es opcional.
Git	Control de versiones	GPLv2 [26]	S/ 0	No	—
GitHub	Alojamiento del repositorio	Servicio (plan Free) [27]	S/ 0 con límites	No	Servicio con límites; verificar precios vigentes.
Cloudflare Tunnel	Acceso desde Internet	Servicio [28]	Condicional	No	Requiere cuenta y dominio para túnel estable [29]. **Opcional.**

Costos que el software gratuito no cubre

Hardware o equipo servidor, electricidad, conexión a Internet, dominio (si no lo provee la institución), almacenamiento y copias de seguridad, y tiempo de mantenimiento. Estos costos dependen de la infraestructura del CEE y de la UNI, y deben conversarse en la reunión.

9. Alternativas tecnológicas

Se comparan alternativas por criterios técnicos. **No se declara un "ganador" ni se usan puntuaciones:** se indica qué encaja mejor en este escenario y por qué. Las características se toman de las fuentes citadas; donde una fuente es secundaria, se señala.

9.1 Ejecución del LLM local

Alternativa	Licencia	Características relevantes	Consideraciones
Ollama	MIT [1]	CLI y API REST; biblioteca de modelos; imagen Docker oficial; usa llama.cpp como motor [1].	Ofrece también modelos en su nube (de pago); usar solo los locales.
llama.cpp	MIT [10]	Motor en C/C++; funciona en CPU y en varias GPU; cuantización de 1,5 a 8 bits; servidor compatible con la API de OpenAI [10].	Más control, pero exige gestionar manualmente los archivos de modelos y su configuración.
vLLM	Apache 2.0 [11]	Motor de servicio de alto rendimiento (PagedAttention, procesamiento por lotes continuo) [11].	Orientado a servir con alta concurrencia; sus requisitos de hardware deben verificarse en su documentación antes de considerarlo.

Encaje con el escenario: como el hardware es desconocido y el equipo del CEE probablemente sea reducido, un servidor de modelos fácil de instalar y operar (Ollama) reduce el esfuerzo inicial. Si las pruebas de carga mostraran que hace falta más rendimiento, llama.cpp o vLLM podrían evaluarse después, ya que ambos usan API compatibles con clientes estándar. **PROPUESTA**

9.2 Base vectorial

Alternativa	Licencia	Características relevantes	Consideraciones
ChromaDB	Apache 2.0 [7]	Base vectorial con metadatos, filtros y API pequeña; funciona en memoria, persistente o cliente-servidor [7].	Versiones frecuentes; validar con el volumen real.
FAISS	MIT [9]	Biblioteca de búsqueda por similitud, optimizada para CPU y GPU; maneja volúmenes muy grandes [9].	Es una biblioteca de búsqueda, sin las funciones de una base de datos tradicional; metadatos y persistencia quedan a cargo del desarrollador [9].
Qdrant	Apache 2.0 [9]	Base vectorial de código abierto para búsquedas de alto rendimiento; opciones local y en la nube [9].	Es un servicio adicional a operar.
Milvus	Apache 2.0 [9]	Base vectorial de código abierto diseñada para escalas muy grandes [9].	Su arquitectura completa es más compleja; pensada para volúmenes mucho mayores. Fuente parcial del fabricante.

Encaje con el escenario: el volumen de documentos de un centro de estudios es, en principio, moderado; ChromaDB ofrece metadatos, persistencia y una API simple sin operar un clúster. FAISS, Qdrant o Milvus serían opciones si los datos crecieran mucho o se requirieran características específicas; la migración es viable porque el backend aísla el acceso a la base vectorial. **PROPUESTA**

9.3 Backend, frontend y base de datos

Categoría	Alternativa	Licencia	Características relevantes	Consideraciones
Backend	FastAPI	MIT [12]	Framework de API con soporte asíncrono (asyncio) [12].	Encaja con flujos de espera larga (generación de texto en streaming).
	Flask	BSD-3-Clause [13]	Framework ligero (WSGI); no impone dependencias ni estructura de proyecto [13].	Válido; el modelo asíncrono y las extensiones dependen de lo que se agregue.
Frontend	React	MIT [14]	Biblioteca para construir interfaces.	La elección entre React y Vue depende más de la experiencia del equipo que de la licencia.
	Vue	MIT [16]	Framework progresivo para interfaces.	Igualmente apto para un chat web.
Base de datos	SQLite	Dominio público [17]	Embebida en un archivo, sin servidor.	Suficiente para el MVP; escrituras concurrentes intensas son su límite natural.
	PostgreSQL	PostgreSQL License [18]	Base de datos con servidor, pensada para múltiples usuarios.	Requiere operar un servicio adicional; conviene cuando crezca la concurrencia.

Encaje con el escenario: FastAPI comparte lenguaje con el ecosistema de IA y encaja con solicitudes que tardan en responder; React o Vue son equivalentes para este caso y se elegirá según la experiencia del equipo; SQLite reduce la operación inicial y PostgreSQL queda como camino de crecimiento. **PROPUESTA**

10. Disponibilidad 24/7

Lectura honesta del requisito

"24/7" significa que el sistema **puede estar disponible de forma permanente**, pero no se puede garantizar disponibilidad absoluta sin infraestructura adecuada. Para una operación estable, el equipo que aloja el sistema debe permanecer encendido y conectado.

Dependencia	Qué puede fallar	Mitigación preliminar
Energía eléctrica	Cortes o variaciones de voltaje.	Consultar a TI si hay respaldo eléctrico; inicio automático de los contenedores tras el reinicio [22].
Hardware	Falla de disco, memoria o del equipo.	Copias de seguridad y documentación para restaurar en otro equipo.
Conexión a Internet	Caídas que impidan el acceso externo.	El procesamiento de IA es local; solo el acceso desde fuera depende de Internet.
Sistema operativo	Actualizaciones que reinician o rompen dependencias.	Ventanas de mantenimiento; versiones fijadas.
Temperatura y ventilación	Sobrecalentamiento con carga sostenida de CPU/GPU.	Ubicación adecuada del equipo; monitoreo básico.
Almacenamiento	Disco lleno por modelos, logs y bases vectoriales.	Monitoreo de espacio; rotación de logs.
Recursos de CPU/GPU/RAM	Saturación con varios usuarios.	Pruebas de carga, límites de concurrencia y cola de solicitudes.
Mantenimiento	Nadie asignado a supervisar y actualizar.	Designar un responsable y entregar un manual de operación.
Copias de seguridad	Pérdida de conversaciones o de la base vectorial.	Respaldos programados y pruebas de restauración.
Acceso externo (Cloudflare Tunnel)	El túnel se cae o cambia su servicio gratuito.	Es opcional; no reemplaza al servidor [29].

11. Escalabilidad

No se inventan cifras de capacidad. Cuántos alumnos puede atender el sistema depende del hardware, del modelo LLM elegido, del tamaño del contexto y de cuántos consultan al mismo tiempo. Registrar 500 alumnos no equivale a 500 usuarios simultáneos: lo que importa es la concurrencia. En Ollama, las solicitudes en paralelo multiplican la memoria de contexto [4].

Escenario	Qué habría que evaluar	Cómo se evaluaría
10 alumnos	Si la latencia es aceptable con pocas consultas simultáneas.	Prueba funcional y medición de tiempo de respuesta.
50 alumnos	Probabilidad de consultas simultáneas; uso de memoria.	Prueba de concurrencia con solicitudes simultáneas simuladas.
100 alumnos	Posibles colas de espera; necesidad de limitar solicitudes por usuario.	Prueba de carga y análisis de cola.
500 alumnos	Si el hardware y el modelo alcanzan o se requiere más capacidad.	Prueba de carga sostenida y decisión sobre hardware o modelo.
Varias consultas a la vez	Cómo se reparte la capacidad entre solicitudes.	Medición de tiempos, memoria y CPU/GPU con concurrencia creciente.

Pruebas propuestas (Fases 8 y 9)

- Pruebas de carga y de concurrencia.
- Pruebas de tiempo de respuesta (primer token y respuesta completa).
- Pruebas de memoria (RAM y VRAM).
- Pruebas de CPU y GPU.
- Pruebas de calidad de la recuperación RAG (¿el fragmento correcto aparece entre los recuperados?).

Palancas de mitigación previstas: cola de solicitudes, límites por usuario, modelo más pequeño, respuestas en streaming, y responder preguntas frecuentes sin invocar al LLM. **PROPUESTA**

12. Seguridad

Sección preliminar propuesta por el Grupo 5. **Deberá validarse con el Área de TI** según las políticas de seguridad del CEE y la UNI.

Aspecto	Medida propuesta
HTTPS	Cifrar la comunicación entre el navegador y el sistema; el certificado dependerá de cómo se exponga el servicio.
Autenticación	Inicio de sesión de alumnos, o acceso abierto solo si TI lo aprueba. A definir en la reunión.
Control de acceso	Roles diferenciados: alumno y administrador de la base de conocimiento.
Protección de credenciales	Sin contraseñas ni claves en el repositorio; uso de variables de entorno o secretos; contraseñas con hash.
Validación de entradas	Límites de longitud y formato en las preguntas; consideración de intentos de manipular el prompt del sistema.
Rate limiting	Límite de solicitudes por usuario y por unidad de tiempo, en Nginx o en la API.
Logs	Registrar eventos de uso y errores evitando guardar datos sensibles innecesarios; definir retención.
Protección de archivos	Permisos restrictivos sobre documentos, bases de datos y volúmenes.
No exponer servicios internos	Solo Nginx accesible desde la red; Ollama y ChromaDB en una red interna de contenedores. Con Cloudflare Tunnel se puede bloquear todo tráfico entrante [28].
Copias de seguridad	Respaldos cifrados y periódicos de SQLite, base vectorial y documentos, con pruebas de restauración.
Protección de datos personales	Cumplir la normativa peruana aplicable (ver sección 13).

13. Privacidad y datos

Se prioriza el **procesamiento local** para reducir la necesidad de enviar información académica o personal a proveedores externos. Con ese principio, las preguntas de los alumnos y los documentos del CEE no salen del servidor, salvo en el tramo de acceso externo si se usa Cloudflare Tunnel (sección 7.13).

Antes de implementar, se debe determinar con el CEE:

Tema	Qué debe definirse
Datos del alumno	Qué datos se almacenarán (identificador, nombre, correo, historial de conversaciones).
Retención	Durante cuánto tiempo se conservarán las conversaciones y los logs.
Acceso	Quién podrá ver los datos y las conversaciones.
Información enviada al modelo	Qué parte del historial y qué datos se incluyen en el prompt.
Logs	Qué información se registrará y por cuánto tiempo.

Marco normativo. En el Perú rige la Ley N.° 29733, Ley de Protección de Datos Personales, cuya reglamentación fue actualizada por el D. S. N.° 016-2024-JUS; la Autoridad Nacional de Protección de Datos Personales corresponde al Ministerio de Justicia y Derechos Humanos [31]. **Este documento no determina las obligaciones específicas** (por ejemplo, consentimiento o registro de bancos de datos): deben ser confirmadas por el área legal o de TI de la UNI/CEE.

14. Control de alucinaciones

> **Límite honesto**
> Ninguna técnica elimina por completo las respuestas incorrectas de un modelo de lenguaje. Las medidas siguientes buscan **reducir** el riesgo, no anularlo.

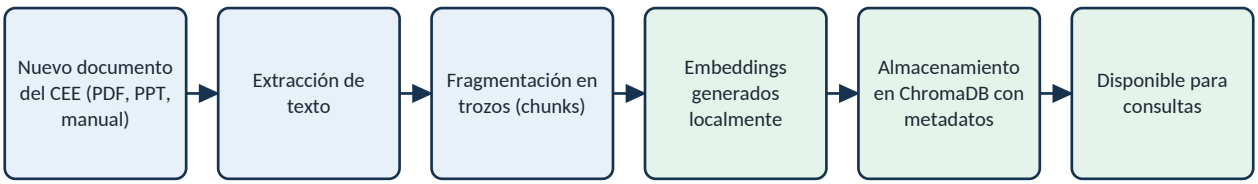
Medida	Cómo ayuda	Límite
RAG	El modelo responde con fragmentos recuperados del material del CEE.	Si se recupera un fragmento equivocado, la respuesta puede fallar.
Fuentes oficiales	La base de conocimiento solo contiene documentos entregados y validados por el CEE.	Depende de que los documentos estén completos y actualizados.
Prompt del sistema	Instruye al modelo a usar solo el contexto y a no inventar.	Los modelos pueden no cumplir siempre las instrucciones.
“Información no encontrada”	Si la recuperación no devuelve contexto suficiente, el tutor lo indica y orienta a un canal humano.	Requiere un umbral de relevancia bien calibrado.
Mostrar fuentes	El alumno puede verificar el documento consultado.	Mostrar una fuente no garantiza que la respuesta la refleje fielmente.
Validación de contenidos	El CEE revisa el material y una muestra de respuestas.	Requiere tiempo y un responsable.
Pruebas con preguntas reales	Detectan errores antes de publicar.	No cubren todas las preguntas posibles.

Ejemplo conceptual de instrucción del sistema (a refinar en las Fases 4 y 8):

```
Eres el Tutor Virtual del Centro de Especialización Ejecutiva FIIS-UNI.
Responde únicamente con base en el contexto proporcionado.
Si el contexto no contiene la información, di que no dispones de información suficiente
y sugiere contactar al CEE. No inventes datos. Indica qué documentos usaste.
```

15. Actualización de la base de conocimiento

Para incorporar un nuevo curso o documento se seguiría este proceso. **No es necesario volver a entrenar el LLM** para cada nuevo documento.



No se reentrena el LLM: solo se incorpora el nuevo contenido a la base vectorial.

Figura 4. Proceso de ingesta de un nuevo documento del CEE.

- Un responsable designado por el CEE entrega el documento validado, con metadatos (curso, versión, fecha de vigencia).
- El sistema extrae el texto, lo divide en fragmentos, calcula los embeddings y los guarda en ChromaDB.
- Los documentos reemplazados se retiran o versionan para evitar respuestas basadas en información antigua.
- Se realiza una prueba corta de preguntas para verificar que el nuevo contenido se recupera correctamente.

El proceso podría iniciarse con un script del equipo y evolucionar hacia una pantalla de administración. **PROPUESTA**

16. MVP propuesto

Incluido en el MVP	Fuera del MVP (por ahora)
Chat web	Pagos
Preguntas sobre cursos	Matrículas
Consulta de documentos	Certificados
RAG	Gestión de notas
LLM local	Gestión completa del Campus Virtual
Explicación de conceptos	Integraciones empresariales complejas
Resúmenes	
Generación de preguntas de práctica	
Contexto de conversación	
Manejo de preguntas sin respuesta	
Historial básico	

El MVP es realista solo si la infraestructura lo permite; su alcance final se confirmará después de la validación de infraestructura (Fase 2) y de la prueba del LLM local (Fase 3). Los criterios de aceptación (por ejemplo, tiempo de respuesta aceptable y número de usuarios simultáneos) se acordarán con TI.

17. Roadmap propuesto

Las fases son secuenciales en general, aunque algunas pueden solaparse. **No se asignan duraciones** porque dependen de los recursos y de las respuestas del CEE.

Fase	Nombre	Objetivo / entregable
1	Levantamiento de requerimientos	Requerimientos funcionales y no funcionales confirmados con el CEE.
2	Validación de infraestructura	Inventario del equipo disponible (CPU, RAM, GPU, red) y decisión de alojamiento.
3	Prueba de LLM local	Evaluación de uno o más modelos en el hardware real; elección del modelo.
4	Implementación del RAG	Ingesta, embeddings, ChromaDB y recuperación funcionando.
5	Backend	API FastAPI con conversaciones, logs y SQLite.
6	Frontend	Interfaz de chat con historial y fuentes.
7	Integración	Todos los componentes trabajando juntos en contenedores.
8	Pruebas	Pruebas funcionales, de calidad de respuestas y de seguridad.
9	Pruebas de carga	Concurrencia, tiempos, memoria y CPU/GPU.
10	Despliegue	Puesta en marcha en el equipo o infraestructura acordada.
11	Monitoreo y mantenimiento	Seguimiento, copias de seguridad y actualización de la base de conocimiento.

18. Preguntas pendientes para el Área de TI del CEE

Estas respuestas permiten decidir el modelo, la infraestructura y el alcance del MVP.

N.°	Pregunta	Decisión que informa
1	¿El CEE dispone actualmente de un servidor?	Alojamiento
2	¿Existe una PC que pueda permanecer encendida 24/7?	Alojamiento y disponibilidad
3	¿Existe infraestructura de la UNI disponible?	Alojamiento
4	¿Qué sistema operativo utilizan?	Compatibilidad (Ubuntu, Docker)
5	¿Cuánta RAM tiene el equipo disponible?	Elección del modelo LLM
6	¿Qué procesador tiene?	Elección del modelo LLM
7	¿Tiene GPU?	Elección del modelo LLM
8	¿Cuánta VRAM tiene?	Tamaño de modelo y concurrencia
9	¿Qué velocidad de Internet tienen?	Acceso externo
10	¿Disponen de IP pública o infraestructura equivalente?	Acceso externo
11	¿Disponen de un dominio?	Acceso externo (Cloudflare Tunnel)
12	¿Pueden instalar Docker?	Despliegue
13	¿Pueden instalar software open source?	Despliegue
14	¿Qué documentos académicos pueden proporcionar?	Base de conocimiento
15	¿Quién administrará la base de conocimiento?	Actualización y mantenimiento
16	¿Qué cantidad aproximada de alumnos utilizaría el sistema?	Escalabilidad
17	¿Cuántos usuarios simultáneos esperan?	Escalabilidad
18	¿Qué información de los alumnos puede almacenarse?	Privacidad
19	¿Qué políticas de seguridad deben cumplirse?	Seguridad
20	¿Qué otros sistemas del CEE deberán integrarse posteriormente?	Arquitectura e integración
21	¿Se considera a la UNI entidad gubernamental para efectos de licencias como Docker Desktop? (adicional del Grupo 5)	Licenciamiento
22	¿Puede TI proveer un subdominio institucional y certificados HTTPS? (adicional)	Acceso externo y costos
23	¿Existen políticas de respaldo, retención de datos y ubicación de los datos? (adicional)	Seguridad y privacidad

19. Riesgos

19.1 Metodología de la matriz

Impacto se clasifica así: **Alto** = el sistema queda inutilizable, entrega información incorrecta a alumnos o expone datos; **Medio** = degrada la experiencia o exige intervención manual; **Bajo** = molestia acotada. **Probabilidad no se cuantifica** porque hoy no se conocen la infraestructura, la carga ni las políticas del CEE: se expresa como la **condición de la que depende** y la pregunta de la sección 18 que la resolverá. Se reevaluará tras la respuesta de TI.

19.2 Matriz de riesgos

Riesgo	Impacto	Probabilidad (depende de)	Mitigación
Hardware insuficiente	Alto	Preguntas 1 a 8	Validar infraestructura antes de elegir el modelo; ajustar el modelo o el alcance.
Falta de GPU	Medio	Pregunta 7	Evaluar modelos pequeños en CPU y medir la latencia; replantear el alcance si no es aceptable.
RAM insuficiente	Alto	Pregunta 5	Cuantización, modelo menor y límite de contexto y concurrencia.
Modelo demasiado pesado	Medio	Resultado de la Fase 3	Evaluar varios modelos con criterios definidos y elegir el que el equipo pueda sostener.
Demasiados usuarios simultáneos	Alto	Preguntas 16 y 17	Cola de solicitudes, límites por usuario, streaming y pruebas de carga.
Caída de Internet	Medio	Pregunta 9	El procesamiento es local; solo el acceso externo se ve afectado.
Corte de energía	Alto	Preguntas 1 y 2	Inicio automático de contenedores [22]; consultar respaldo eléctrico. No hay garantía absoluta.
Documentación insuficiente	Alto	Pregunta 14	Inventario temprano de documentos; el tutor responde “información no encontrada”.
Información desactualizada	Medio	Pregunta 15	Responsable de contenido, fecha de vigencia por documento y proceso de actualización.
Respuestas incorrectas	Alto	Inherente a los LLM	RAG, prompt del sistema, fuentes visibles, validación por el CEE y pruebas; no se elimina por completo.
Pérdida de datos	Alto	Pregunta 23	Respaldos periódicos y pruebas de restauración.
Problemas de seguridad	Alto	Pregunta 19	Medidas de la sección 12; no exponer servicios internos; revisión con TI.
Falta de personal de mantenimiento	Medio	Pregunta 15	Docker Compose para reproducir el entorno; manual de operación; responsable designado.
Costos no previstos (dominio, equipo, energía)	Medio	Preguntas 11 y 22	Declararlos en la propuesta; usar dominio o infraestructura institucional.
Cambios de condiciones de terceros (Ollama Cloud, Docker Desktop, GitHub, Cloudflare)	Medio	Externa	Usar solo componentes locales; fijar versiones; no depender de servicios de terceros para el funcionamiento base.

20. Decisiones para la reunión con TI

Se propone que la reunión del domingo 20 de septiembre (3:00 p. m. si no se acuerda otra hora) cierre, como mínimo, estas decisiones:

N.°	Decisión	Propuesta inicial del Grupo 5
1	Dónde se alojará el sistema	PC o servidor del CEE, o infraestructura institucional que TI indique.
2	Modalidad de acceso	Comenzar en red interna; evaluar acceso desde Internet con dominio institucional.
3	Autenticación	Inicio de sesión de alumnos, salvo que TI apruebe acceso abierto.
4	Base de conocimiento inicial	Lista de documentos, formato y responsable de mantenerla.
5	Datos de alumnos	Qué se guarda, por cuánto tiempo y quién accede.
6	Prueba del LLM local	Autorizar la instalación de Ollama y pruebas en el equipo elegido (Fase 3).
7	Política de contenedores	Usar Docker Engine sobre Ubuntu; no Docker Desktop.

N.°	Decisión	Propuesta inicial del Grupo 5
8	Criterios de aceptación del MVP	Tiempo de respuesta y usuarios simultáneos aceptables.
9	Canal humano de derivación	Contacto del CEE al que el tutor remite las consultas sin respuesta.

21. Conclusión

La arquitectura propuesta preliminarmente busca cumplir:

- **Costo de software:** S/ 0.
- **Sin pago por tokens.**
- **Sin dependencia de APIs comerciales de IA.**
- **Procesamiento local** de consultas y documentos.
- **RAG basado en la documentación del CEE.**
- **Arquitectura modular**, con posibilidad de crecimiento.
- **Control sobre los datos.**

> **La viabilidad final depende de:**
> 1) infraestructura disponible; 2) hardware; 3) RAM; 4) CPU/GPU; 5) número de usuarios; 6) calidad y cantidad de documentación; 7) requerimientos de TI; 8) políticas de seguridad; y 9) conectividad.

Hasta que el Área de TI confirme esos puntos, este documento debe leerse como una **propuesta de trabajo**: el stack y la arquitectura están listos para debatirse, pero el modelo de IA, la infraestructura y el alcance final del MVP quedan por definir. El Grupo 5 queda a disposición para ajustar la propuesta con las observaciones de la reunión.

Referencias

Consultadas el 19 de septiembre de 2026. Las marcadas como **fuente secundaria** no son documentación oficial y deben contrastarse antes de tomar decisiones definitivas. Las licencias y precios pueden cambiar; deben reconfirmarse al momento de decidir.

[1] Ollama. Repositorio oficial (licencia MIT, API REST local, imagen Docker oficial, motor llama.cpp).
https://github.com/ollama/ollama

[2] Ollama. Documentación oficial de la API REST.
https://docs.ollama.com/api

[3] Ollama Cloud: planes, límites y precios. FUENTE SECUNDARIA; contrastar con la página oficial de precios de Ollama antes de decidir.
https://ollamatps.com/limits/
https://omidsaffari.com/blog/ollama-pricing

[4] Requisitos de hardware de Ollama (memoria, contexto, concurrencia) y estimaciones de VRAM por tamaño de modelo. FUENTES SECUNDARIAS; son orientativas, no especificaciones oficiales.
https://shop.zimaspace.com/en-ca/pages/ollama-hardware-requirements
https://www.hostinger.com/tutorials/?p=156543

[5] Google lanza Gemma 4 con licencia Apache 2.0 (abril de 2026). FUENTE SECUNDARIA; verificar en la ficha oficial del modelo.
https://finder.techleap.nl/news/feed/google-launches-gemma-4-open-ai-models-switches-to-apache-2-0-license

[6] Comparativa de licencias de LLM abiertos en 2026 (Qwen, Gemma, Llama). FUENTE SECUNDARIA; verificar en la ficha oficial de cada modelo.
https://datanorth.ai/blog/the-best-open-source-llm-in-2026

[7] Chroma. Repositorio oficial (licencia Apache 2.0, modo cliente-servidor, Chroma Cloud como servicio aparte).
https://github.com/chroma-core/chroma

[8] Sentence Transformers (UKPLab; mantenido por Hugging Face). Repositorio y documentación (licencia Apache 2.0).
https://github.com/UKPLab/sentence-transformers

[9] Comparativas de bases vectoriales (FAISS, Qdrant, Milvus, Chroma). FUENTES SECUNDARIAS; una es del fabricante de Milvus (posible sesgo).
https://zilliz.com/pt/comparison/qdrant-vs-faiss
https://research.aimultiple.com/entity-linking

[10] llama.cpp. Repositorio oficial (licencia MIT, inferencia en CPU/GPU, cuantización, servidor compatible con la API de OpenAI).
https://github.com/ggml-org/llama.cpp

[11] vLLM. Repositorio oficial (licencia Apache 2.0, motor de servicio de alto rendimiento).
https://github.com/vllm-project/vllm

[12] FastAPI. Sitio y repositorio oficiales (licencia MIT).
https://fastapi.tiangolo.com/
https://github.com/fastapi/fastapi

[13] Flask (Pallets). Documentación y texto de licencia BSD-3-Clause.
https://flask.palletsprojects.com/
https://flask-es.readthedocs.io/license/

[14] React. Repositorio oficial (licencia MIT).
https://github.com/facebook/react

[15] Vite. Sitio oficial. La licencia MIT y el requisito de Node.js provienen de los metadatos del paquete create-vite (fuente secundaria).
https://vite.dev
https://mcp.depscope.dev/pkg/npm/create-vite

[16] Vue.js. Repositorio oficial (licencia MIT).
https://github.com/vuejs/core

[17] SQLite. Página oficial de licencia (dominio público).
https://www.sqlite.org/copyright.html

[18] PostgreSQL. Página oficial de licencia (PostgreSQL License).
https://www.postgresql.org/about/licence/

[19] Nginx. Licencia BSD de 2 cláusulas (archivo LICENSE y preguntas frecuentes del sitio oficial).
https://nginx.org/LICENSE

[20] Docker. Acuerdo de licencia de Docker Desktop (suscripción de pago para entidades gubernamentales y organizaciones grandes; términos de Docker Engine sin cambios).
https://docs.docker.com/subscription-billing/desktop-license/

[21] Docker (software). Licencia de Docker Engine (Apache 2.0, Linux). FUENTE SECUNDARIA (enciclopedia).
https://en.wikipedia.org/wiki/Docker_(software)

[22] Docker. Documentación oficial: iniciar contenedores automáticamente.
https://docs.docker.com/engine/containers/start-containers-automatically/

[23] Docker Compose. Repositorio oficial (licencia Apache 2.0).
https://github.com/docker/compose

[24] Ubuntu Server. Página oficial de descarga (LTS con 5 años de actualizaciones de seguridad gratuitas; requisitos mínimos de instalación).
https://ubuntu.com/server/download

[25] Python. Historia y licencia (Python Software Foundation License).
https://docs.python.org/3/license.html

[26] Git. Página oficial: software libre y de código abierto (GPLv2).
https://git-scm.com/about/free-and-open-source

[27] GitHub. Documentación de planes (versión consultada: Enterprise Server 3.13) y página de precios vigente. Contrastar con la página de precios antes de decidir.
https://docs.github.com/en/enterprise-server@3.13/get-started/learning-about-github/githubs-plans
https://github.com/pricing

[28] Cloudflare. Documentación de Cloudflare Tunnel (conexiones solo salientes, sin IP pública enrutable).
https://developers.cloudflare.com/cloudflare-one/networks/connectors/cloudflare-tunnel/
https://developers.cloudflare.com/cloudflare-one/networks/connectivity-options/

[29] Cloudflare. Túneles rápidos (sin garantía de disponibilidad) frente a túneles con nombre (requieren cuenta y zona propia).
https://developers.cloudflare.com/sandbox/api/tunnels/

[30] Cloudflare. Planes de Zero Trust (oficial) y análisis de los límites del plan gratuito, incluido el tope de 50 usuarios (FUENTE SECUNDARIA).
https://www.cloudflare.com/plans/zero-trust-services/
https://zerometric.net/research/cloudflare-zero-trust-free-plan-limits-2026/

[31] Perú. Ley N.° 29733, Ley de Protección de Datos Personales, y Decreto Supremo N.° 016-2024-JUS (reglamento actualizado; el Ministerio de Justicia ejerce la Autoridad Nacional).
https://www.congreso.gob.pe/Docs/DGP/DIDP/files/ley_29733.pdf
https://www.congreso.gob.pe/Docs/DGP/DIDP/files/ds_016-2024-jus.pdf